Fin DataScience

Credit Risk Scoring — Vue d'ensemble du projet

Document de synthèse (lecture A à Z du dépôt de travail)

1. Objectif du projet

Ce projet est un travail de **Finance Data Science** visant à construire un pipeline complet de **scoring du risque de crédit** pour des prêts à la consommation. L'objectif principal est de **prédire la probabilité de défaut** d'un emprunteur (variable cible **loan_status** : 0 = remboursement, 1 = défaut) à partir des caractéristiques de la demande et du profil client, puis de traduire ces prédictions en décisions et impacts métier (approbation, segmentation, perte attendue).

Le notebook **Credit_Risk_Scoring.ipynb** suit un flux professionnel en quatre volets :

- **Partie 1** — Exploration et préparation des données (EDA, outliers, feature engineering).
- **Partie 2** — Construction et évaluation de trois modèles : régression logistique, XGBoost, LightGBM.
- **Partie 3** — Opérationnalisation : segments de risque, règle d'approbation, analyse de perte attendue (EL).
- **Chapitre 4** — Comparaison des modèles, choix stratégique et recommandations pour une institution de crédit.

En résumé, l'objectif n'est pas seulement d'obtenir un bon AUC, mais de montrer comment un modèle ML s'intègre dans la gestion du risque : équilibre entre **rappel sur les défauts** (éviter d'accorder de mauvais prêts) et **précision** (ne pas rejeter inutilement de bons clients), alignement réglementaire (interprétabilité) et quantification économique (PD, EL).

2. Contenu du dépôt (inventaire)

Fichier	Rôle
Credit_Risk_Scoring.ipynb	Notebook principal : workflow ML + business
cr_loan2.csv	Jeu de données (~32 000+ demandes de prêt)
.Rhistory	Historique R (artefact local, hors pipeline Python)

3. Données utilisées

Source unique : **cr_loan2.csv**. Variables principales (sens métier) :

Variable	Type	Signification
person_age	Numérique	Âge du demandeur
person_income	Numérique	Revenu annuel
person_home_ownership	Catégorielle	Statut logement (RENT, OWN, MORTGAGE…)
person_emp_length	Numérique	Ancienneté emploi (années)
loan_intent	Catégorielle	Objet du prêt
loan_grade	Catégorielle	Note interne de risque

loan_amnt / loan_int_rate	Numérique	Montant et taux d'intérêt
loan_percent_income	Numérique	Part du revenu consacrée au prêt
cb_person_default_on_file	Catégorielle	Défaut antérieur (Y/N)
cb_person_cred_hist_length	Numérique	Longueur historique crédit
loan_status	Cible	0 = non-défaut, 1 = défaut

4. Méthodologie (résumé A à Z)

4.1 Partie 1 — Exploration et préparation

- Inspection : dimensions, types, valeurs manquantes, doublons, statistiques descriptives.
- EDA : distribution de la cible, histogrammes, boxplots, countplots, heatmap de corrélation, analyse défaut vs non-défaut.
- Outliers : méthode IQR (Q1 – 1,5×IQR, Q3 + 1,5×IQR) avec winsorisation (clip) sur variables numériques clés.
- Traitement : imputation médiane (emploi ; taux par grade de prêt), suppression des doublons.
- Feature engineering : prior_default_flag, short_credit_history, high_payment_burden, income_to_loan_ratio, annual_interest_cost, income_tier, age_group.
- Encodage one-hot des catégories, StandardScaler (ajusté sur train uniquement), split train/test stratifié (random_state=42).

4.2 Partie 2 — Modélisation

Trois classificateurs binaires comparés sur le même jeu de test, avec métriques Accuracy, Precision, Recall, F1, ROC-AUC, matrices de confusion et courbes ROC :

Modèle	**Rôle / particularité**
Régression logistique	Baseline interprétable (coefficients, log-odds, PD) ; features standardisées.
XGBoost	Gradient boosting ; scale_pos_weight pour déséquilibre des classes ; features non scalées.
LightGBM	Boosting leaf-wise, histogrammes ; adapté aux grands jeux tabulaires.

Analyse d'erreurs : interprétation métier des faux positifs (bon client rejeté) et faux négatifs (mauvais prêt accordé). Importance des variables (coefficients LR, gain XGBoost, importance LightGBM).

4.3 Partie 3 — Opérationnalisation

Sur le portefeuille test, utilisation de la **probabilité de défaut (PD)** prédite par le modèle retenu pour l'opérationnel :

Segment	**Plage PD**	**Politique indicative**
Faible risque	PD < 15 %	Approbation — tarification standard
Risque moyen	15 % ≤ PD < 35 %	Approbation avec suivi / taux plus élevé
Risque élevé	PD ≥ 35 %	Rejet ou garanties

Règle implémentée dans le notebook : approuver si PD < 30 %, sinon rejeter. Calcul de la **perte attendue** : EL = PD × LGD × EAD, avec LGD = 45 % (hypothèse prêt non garanti) et EAD = montant du prêt (loan_amnt). Visualisation de l'EL par segment et comparaison EL sur dossiers approuvés vs rejetés.

4.4 Chapitre 4 — Stratégie

- Tableau comparatif des métriques entre les trois modèles (meilleur modèle identifié notamment via ROC-AUC).
- Discussion : performance vs interprétabilité, coût de calcul, transparence réglementaire (scorecards vs modèles challenger).
- Recommandations : tarification basée sur le risque, approbation automatisée hybride (règles + score ML), monitoring des segments moyens, segmentation portefeuille, réduction de l'EL.
- Pistes d'amélioration : données bureau supplémentaires, CatBoost, ensembles, calibration PD, SHAP, stress tests.

5. Outils et bibliothèques utilisés

5.1 Environnement et langage

Python 3 exécuté dans un **Jupyter Notebook** (Credit_Risk_Scoring.ipynb). Pas de fichier requirements.txt dans le dépôt ; les imports du notebook définissent la stack.

5.2 Bibliothèques Python

Catégorie	Bibliothèque	Usage dans le projet
Données	pandas, numpy	Chargement CSV, manipulation, features, agrégations
Visualisation	matplotlib, seaborn	Graphiques EDA, heatmaps, ROC, EL
ML — scikit-learn	sklearn	Split, StandardScaler, LogisticRegression, métriques, ROC
ML — boosting	xgboost (XGBClassifier)	Modèle gradient boosting
ML — boosting	lightgbm	Modèle LightGBM
Stdlib	warnings	Filtrage des avertissements

5.3 Concepts métier / réglementaires cités

PD (Probability of Default), EL (Expected Loss), LGD, EAD, IFRS 9 / Basel IRB (calibration PD), principes de gouvernance des modèles (SR 11-7 / ECB TRIM), scorecards vs modèles challenger.

6. Principaux facteurs de risque identifiés

- Charge de remboursement : loan_percent_income, high_payment_burden.
- Signaux de tarification : loan_int_rate, loan_grade.
- Historique bureau : prior_default_flag, cb_person_cred_hist_length.
- Capacité de remboursement : person_income, income_to_loan_ratio.

7. Limites mentionnées dans le projet

- Données transversales (pas de validation out-of-time ni stress macro).
- loan_grade potentiellement endogène au moment de la demande.
- LGD et EAD simplifiés ; pas d'inférence sur les rejets (reject inference).

Document généré automatiquement à partir de l'analyse du dépôt Fin DataScience.